

分类号: F830.59

密 级: 公开

单位代码: 10422

学 号: 201911979



山东大学
SHANDONG UNIVERSITY

硕士学位论文

Thesis for Master Degree

论文题目: 基于机器学习方法的 MACD 择时策略优化
The Optimization of MACD Timing Strategy
Based on Machine Learning Methods

作者姓名	郭凝
培养单位	中泰证券金融研究院
专业名称	统计学
指导教师	贾广岩 教授
合作导师	

2022 年 05 月 23 日

摘 要

在股票市场预测领域，预测未来价格或走势是最具挑战性的问题之一。近年来，随着机器学习技术的发展，人们在股价预测的相关研究中，越来越多的在传统金融分析技术中引入机器学习模型，将机器学习技术与传统技术分析指标相结合以预测股市趋势。

本文提出了一种基于机器学习的混合技术分析交易策略，通过机器学习技术以优化传统方法产生的买入或卖出交易信号，从而提高收益。这种方法的创新之处在于使用机器学习方法预测未来股价，定义并计算出一种新的趋势指标，将其与技术分析指标结合进行优化。为了选择最合适的机器学习技术，本文介绍并分析使用了支持向量回归、随机森林和人工神经网络三种方法在股票市场的预测效果。选择 MACD 择时策略作为本文研究交易信号的基本技术策略，同时对于 MACD 参数的选择，使用网格搜索计算最优参数。

自 2020 年新冠疫情以来，我国股票市场受到了诸多影响，为了客观分析本文提出的混合交易策略对投资收益的提高效果，本文将实证研究分为两个时期：疫情前阶段和疫情后阶段，并使用国内三大指数，上证 50、沪深 300 和中证 500 的每日交易数据进行回测。本文首先以上证 50 指数为例，比较三种机器学习方法的预测精度，根据预测结果选择随机森林方法作为最优股票价格预测方法，然后使用 2018 年和 2020 年的数据分别计算最优 MACD 参数，最后回测分析优化策略的盈利效果，并对沪深 300 和中证 500 也进行了策略回测。结果表明，在技术分析策略中加入机器学习趋势指标，可以改善交易信号，提高技术分析策略的竞争力。该策略在行情向好时可以抓住时机，大幅提高利润。在股市影响因素较多、波动较大时，该策略也可以有效避开价格震荡区域，减小风险。

关键词：技术分析；股市预测；机器学习；投资策略

ABSTRACT

In the field of stock market prediction, predicting the future price or trend is one of the most challenging problem. In recent years, with the development of machine learning technology, in the related research of stock price prediction, more and more people have introduced machine learning models into traditional financial analysis technology and combined machine learning technology with traditional technical analysis indicators to predict the trend of the stock market.

This paper proposes a hybrid technology analysis trading strategy based on machine learning, which optimizes the buying or selling trading signals generated by traditional methods through machine learning technology so as to improve income. The innovation of this method is to use the machine learning method to predict the future stock price, and define and calculate a new trend index, which is combined with the technical analysis index for optimization. In order to choose the most suitable machine learning technology, this paper introduces and analyzes the prediction effect of three methods: support vector regression, random forest, and artificial neural network in the stock market. MACD timing strategy is selected as the basic technical strategy of this paper. At the same time, for the selection of MACD parameters, grid search is used to calculate the optimal parameters.

Since the outbreak of COVID-19, China's stock market has been affected by many factors. In order to objectively analyze the effect of the hybrid trading strategy proposed in this paper on the improvement of investment income, this paper divides the empirical research into two stages: the pre-epidemic stage and the post epidemic stage, using the daily trading data of the three major domestic indexes, SSE 50, CSI300 and CSI500 to backtest. Firstly, SSE50 index is taken as an example. This paper compares the prediction accuracy of three machine learning methods and selects the random forest method as the optimal stock price prediction method based on the prediction results, then uses the data of 2018 and 2020 to calculate the optimal MACD parameters respectively, finally backtests and analyzes the profit effect of the optimization strategy, and also backtests the strategies of CSI 300 and CSI 500. The result shows that adding the machine learning trend index to the technical analysis strategy can improve the transaction signal and the competitiveness of the technical analysis strategy. This strategy can seize the opportunity and greatly increase profits when the market

is good. When there are many influence factors and large fluctuations in the stock market, this strategy can also effectively avoid the price shock area and reduce the risk.

Keywords: Technical analysis; Stock market forecasting; Machine learning; Investment strategy

目 录

摘 要.....I

ABSTRACT..... II

1 绪论..... 1

 1.1 研究背景与研究意义..... 1

 1.2 国内外研究现状..... 2

 1.3 研究内容和创新点..... 4

2 股票市场价值预测..... 6

 2.1 股票市场价值理论..... 6

 2.2 机器学习预测模型..... 6

 2.2.1 支持向量回归..... 6

 2.2.2 人工神经网络..... 9

 2.2.3 随机森林..... 11

 2.3 评价指标..... 13

3 股票市场技术分析策略..... 14

 3.1 技术分析基础理论..... 14

 3.1.1 技术分析有效性..... 14

 3.1.2 技术分析理论..... 15

 3.2 技术分析指标..... 16

 3.2.1 指数移动平均线(EMA)..... 16

 3.2.2 指数平滑异同移动平均线(MACD)..... 16

 3.3 MACD 择时策略..... 17

 3.4 混合机器学习与技术分析策略..... 17

 3.4.1 混合技术分析策略构建流程..... 17

 3.4.2 混合策略规则..... 19

 3.5 评价指标..... 20

4 实证分析..... 22

 4.1 数据的来源和选取..... 22

 4.2 机器学习模型选择..... 23

 4.3 MACD 策略参数优化..... 28

4.4 回溯测试交易策略..... 29

4.5 沪深 300 和中证 500 实证分析..... 33

结 论..... 39

参考文献..... 41

致 谢..... 43

CONTENTS

ABSTRACT(In Chinese) I

ABSTRACT II

1 Introduction 1

 1.1 Research Background and Significance 1

 1.2 Research Status at Home and Abroad 2

 1.3 Research Content and Innovation 4

2 Theory of Stock Market Value Prediction 6

 2.1 Stock Market Value Theory 6

 2.2 Machine Learning Prediction Models 6

 2.2.1 Support Vector Regression 6

 2.2.2 Artificial Neural Networks 9

 2.2.3 Random Forest 11

 2.3 Evaluation Indicators 13

3 Stock Market Technical Analysis Strategies 14

 3.1 Basic Theory of Technical Analysis 14

 3.1.1 Technical Analysis Effectiveness 14

 3.1.2 Technical Snalysis Theory 15

 3.2 Technical Analysis Indicators 16

 3.2.1 Exponential Moving Average (EMA) 16

 3.2.2 Moving Average Convergence Divergence (MACD) 16

 3.3 MACD Timing Strategy 17

 3.4 Machine Learning and Technical Analysis Strategies 17

 3.4.1 Mixed Technical Analysis Strategy Building Process 17

 3.4.2 Mixed Strategy Rule 19

 3.5 Evaluation indicators 20

4 Empirical Analysis 22

 4.1 Data Overview 22

 4.2 Machine Learning Model Selection 23

 4.3 The Optimization of MACD Parameters 28

4.4 Backtesting Trading Strategies..... 29

4.5 Empirical Analysis of CSI 300 and CSI 500..... 33

Conclusion..... 39

Reference..... 41

Acknowledgements 43

1 绪论

1.1 研究背景与研究意义

预测股票价格在学术和金融经济领域都是一个越来越受关注的研究方向，通过预测股价，一方面可以指导帮助投资者进行投资、提高收益，另一方面也可以为推动国家的金融经济发展。尽管多年来人们努力开发新的技术策略和研究方法来预测股票价格，但预测效果都不是特别有效。股票市场发展会受到很多复杂因素的协同推动，这使得股价波动具有非线性依赖、很高的统计噪声以及非平稳等特征，也使得股价难以准确预测。

传统上，分析股市数据最常用的两种方法是基本面分析和技术分析。基本面分析通过查看关键数据和经济指标来确定相关公司的经营状况和业绩。目的是识别从根本上强大的公司或行业以及根本上薄弱的公司或行业。主要关注的是长期持有和长期投资，分析侧重的是宏观。但基本面分析具有可掌握性差、信息时效滞后性、信息传播过程中的先后性等问题。而技术分析与此相反，主要为趋势分析、量能分析、时间周期分析和价格波动分析，分析侧重的是微观。它是基于历史数据来预测股票未来的价格走势，该方法主要关注短期价格预测。

自美国经济学家尤金·法玛^[1]于1970年提出有效市场假说（Efficient Markets Hypothesis, EMH）以来，有效市场假说理论已成为金融学的重要基础理论。有效市场假说的产生使得技术分析有效性受到质疑，如果我们需要使用技术分析方法来预测股票市场趋势，首先需要研究技术分析和股票市场的有效性。

在最近的一项工作中，有研究者提出了适应性市场假说（Adaptive Markets Hypothesis, AMH）^[2]，以完善有效市场假说理论的不足，即市场不是完全理性的，而是由恐惧和贪婪驱动的。适应性市场假说从生物进化学的角度分析股票市场的内在机能及其运行方式，该假说认为股票市场本身就处于不断进化与适应学习的过程中，股票市场的参与者投资者在竞争中试错、学习经验来实现进化，以此来适应跟随股票市场的发展变化。适应性市场假说认为，股票市场价格在短期内是可以预测的。另一方面，由于中国股市与发展较早的发达国家股市相比，还存在一些不完善之处，因此市场有效性理论在我国股市的应用也会略弱于发达国家，在学术界很多研究者也认为现阶段我国股票市场状态并不属于有效市场假说中定义的传统“弱有效市场”，所以可以认为技术分析对于我国股票市场还具有一定的效果。由此，技术分析在中国股市预测方面的有效性也得以验证。

除了基本面分析和技术分析外,许多研究者将股价预测问题表述为时间序列预测问题。在这种方法中,基本上有两类技术:传统方法和机器学习方法。传统的策略包括统计分析、回归分析和数据平滑方法等。股价的时间序列建模现在多用自回归移动平均线 (ARIMA) 模型、广义自回归条件异方差 (GARCH) 等模型。不过它们也有一些使用的缺陷,比如很多计量模型是假定了数据符合特定分布,而实际的股票数据的时间序列波动变化很多,这种先行的特定的分布假设往往很难符合。而机器学习算法与之相比,对数据和统计噪声的要求较少,更适合处理具有非线性关系的复杂数据,近年来人们也对基于机器学习的金融分析技术越来越感兴趣。在这一领域中,支持向量回归 (SVR)、随机森林算法 (RF) 和人工神经网络 (ANN) 都是非常流行的方法,并已在许多工作中得到应用。

随着上述机器学习算法近年来在股票市场中的深入应用,股票价格预测模型和交易模型,也从简单的因子选股、以及使用相对强弱指标、随机指标、趋向指标等简单的技术分析指标分析股市,转变为将金融产品价格指标与股票市场中的各指标结合起来、进行定量统计分析的模式,同时在该模式的基础上,使用机器学习算法模型预测股票市场未来趋势,计算出最佳买入卖出点。我国金融市场发展晚于发达国家,与发达国家金融市场相比,我国金融市场仍存在一些不足之处。但近年来我国经济迅速发展,国内金融市场发展也越为迅速和开放,各类金融衍生品也随之增多,将股票投资数量化的方式及相关应用也越来越受到关注。股票市场上采用的技术分析方法和指标有很多,MACD 策略就是最经典的一种。MACD 策略的作用是计算市场的买卖信号及转势点,该策略主要适用于研究和判断股票市场的中长期趋势,判断股市上涨行情或下跌行情的起始时间点与结束时间点。利用 MACD 策略指标,我们可以判断分析当前的股票市场形势及发展趋势、避免逆向操作。与 MA 策略相比,减少了频繁的买入卖出信号,避免了虚假信号的出现。但是当股票市场价格在短期内大幅波动时,由于 MACD 策略发出买入或卖出信号具有滞后性,因此不能根据股市即时波动迅速地产生新的买入卖出信号,也就不利于投资者将该策略用于短期操作;当股价波动幅度较小时,也会导致指标失真,使得 MACD 策略发出的买卖信号不明显。基于此,本文将结合机器学习方法,对 MACD 策略进行优化,帮助投资者提高收益。

1.2 国内外研究现状

国外对于股票市场预测的相关研究有很多,从 Jegadeesh (1990)^[6]提出个股收益可预测性之后,许多学者开始从不同方面对金融资产的可预测性进行探索。Hong 等 (1999)^[5]构建了统一理论来解释资产市场短期内对消息反应不足、长期内对消息反应过度的现象。

关于股票市场的预测,近年来越来越多的研究着眼于各种金融工具的运用。许多学术研究者都付出了巨大的努力来预测股票市场指数的未来走势或收益,并设计金融交易策略来将预测转化为利润。而机器学习技术可以对研究股票趋势提供很大帮助。在早期的工作中,Gencay (1996)^[4]建立了一个前向 ANN 模型,该模型以 DJI 指数的移动平均价格作为输入数据,对 1967-1988 年这二十年间的 DJI 指数进行了预测,研究结果表明,与线性模型相比,ANN 模型具有更好的预测能力。Pesaran 等 (1999)^[7]采用 ANN 算法,对伦敦证券指数进行预测,月变化率的预测准确率达到 60%。Zhang 等 (2003)^[13]分别研究了 ARIMA 模型和 ANN 模型对于时间序列数据的预测效果,并进行对比分析、研究其优劣。研究结果表明:对于非线性数据,ANN 模型预测出的数据精度高于 ARIMA 模型、在数据处理方面具有更好的性能。这篇文章在预测对比结果的基础上,将 ARIMA 模型和 ANN 模型结合,提出了优化混合模型,并通过进一步的实验,证明了该模型可以有效提高预测精度。Teixeira 等 (2010)^[11]结合技术分析和 K 邻近分类器的自动股票交易方法,研究完全基于每日股票收盘价和交易量的智能预测系统实际应用的可行性。Rajashree 等 (2016)^[9]提出了一种使用计算高效的函数连接人工神经网络和一组规则的新型决策支持系统,并将模型性能与支持向量机、朴素贝叶斯模型、K 邻近模型和决策树模型等机器学习技术进行了比较,评估所提出方法的潜在用途。Sang 和 Pierro (2018)^[10]提出使用长短期记忆神经网络来改进技术分析中使用的传统交易算法。对于简单移动平均线 (SMA)、相对强弱线 (RSI) 和指数平滑异同移动平均线 (MACD) 这三种指标,分别将其与神经网络模型进行结合,综合判断分析以确定该混合策略效果。研究结果表明,结合神经网络预测和传统技术分析的策略,优于传统的交易策略。在近两年一项研究中,Aguirre (2020)^[1]提出将 MACD 策略与遗传算法结合,以优化产生买入卖出信号的参数。基于纳斯达克股票指数 2013-2019 年期间的数据,将该改进模型与 MACD 策略进行了比较。

对于股票市场的预测,国内也有很多专家做了深入研究。

王上飞等 (1998)^[25]使用 RBF 神经网络模型,对股票价格进行预测。使用滑动窗口方法,将股价预测问题转化为非线性时间序列预测问题,结果表明 RBF 神经网络模型在股票市场具有较好的预测结果。王永宏等 (2001)^[27]通过研究沪深两市数据分析研究了短期和长期交易策略的可行性。辛治运和顾明 (2008)^[28]使用支持向量回归算法对国内股票市场进行预测,并且取得了较好的预测效果。余乐安和汪寿阳 (2009)^[30]对我国沪深股市进行分析,他们使用了 20 只股票的金融数据进行机器学习,具体使用的方法有聚类分析、遗传规划等算法。计算结果表明上述机器学习算法在股票分类和股价等数据的预测中都有很好的表现。方匡南等 (2010)^[17]为了更好地预测我国基金收益率,使用了一种新的非参数 RF 算法,并和 ARIMA、SVM 等算法的结果进行比较,结果表明,RF 算法与 ARIMA 和 SVM 算法相比,可以更好地预测基金收益率,该研究结果也

在一定程度上证明了国内金融市场趋势是可以预测的。姜富伟等（2011）^[20]根据国内市场投资现状和各行业的规模划分行业行情等，选取各种经济变量进行实验，证明了国内股市的可预测性。韩豫峰等（2014）^[19]通过使用技术分析工具，证明了国内股市存在短期趋势，行为金融学等投资理论同样适用于中国股票市场。杨永洁（2017）^[29]通过将 MACD 策略结果与线性回归和机器学习等方法预测出的收益结合，改进了传统 MACD 策略的交易信号，对 MACD 策略进行优化。研究结果表明，混合 MACD 策略可以有效改善交易信号效率，从而提高收益。陈标金和王锋（2019）^[14]利用机器学习算法构建预测收益率模型，将预测变量分为技术分析指标和宏观经济指标两种。该文章基于随机森林算法构建了 4 种机器学习模型，分别计算了这四种模型的预测效果，通过对比分析模型的预测效果，检验提出指标的预测能力。研究结果表明随机森林算法在国债期货投资模型的构建中，具有很好的效果。

通过上述文献综述研究，我们可以得出如下结论：国内外多项研究结果表明将机器学习应用到股票预测领域，可以提高预测精度，从而提高收益，有利于投资。将机器学习方法与技术分析指标结合，可以优化产生的交易信号，混合策略表现均优于传统策略。但国内研究更侧重于应用机器学习和深度学习算法预测股价，因此本文将提出一种结合机器学习预测趋势指标与 MACD 指标的混合策略，对国内股票市场三大指数进行实证分析。

1.3 研究内容和创新点

本文主要进行了优化股票市场交易策略的研究。将时间分为新冠疫情前和爆发后两个阶段，分别对比分析三种机器学习方法预测股票市场价格的表现，选出预测效果最好精度最高的机器学习方法，将机器学习趋势指标与采用最优参数的技术分析 MACD 策略结合起来，提出了一种新的混合交易策略，以改善产生的交易信号。研究结果表明，将有关预测趋势的信息应用到技术分析中，可以产生更稳健的信号。

本文使用的机器学习技术有：支持向量回归（SVR）、随机森林（RF）和人工神经网络（ANN）。作为技术分析策略，使用了经典的 MACD 择时策略。

本文的主要创新点如下：

（1）研究内容的创新。2020 年初新冠疫情至今，对我国股市造成了持续影响，疫情前和疫情爆发后我国股市情况有了很大变化，因此，本文对疫情前后的股票市场分别进行回测，并评价优化的技术分析策略。

（2）不同模型的效果对比研究。本文使用支持向量回归、随机森林和人工神经网络三种机器学习方法，对比分析了它们在股票市场价格预测方面的效果。

接下来对本文的章节安排进行说明：

第一章首先对本文的选题背景、股票价值预测的现实与理论意义进行了介绍，简单阐述了机器学习方法应用于股票市场的国内外研究发展历史及现状，并对本文的主要研究内容以及整体的结构安排进行了说明。

第二章详细阐述股票市场价值理论和价值预测理论、机器学习预测股票市场价格的基础理论知识和预测效果评价指标。

第三章介绍技术分析基础理论、技术分析指标计算、MACD 择时策略、混合机器学习与技术分析策略规则的构成，最后介绍了回测 MACD 策略与混合 MACD 策略的评价指标。

第四章是本文的实证分析部分。介绍了数据的来源选取，对国内三大指数：上证 50、沪深 300、中证 500 指数进行实证分析，对比了三种机器学习模型对三大指数的预测效果。计算 MACD 策略最优参数，与机器学习趋势指标结合，回溯测试两种交易策略。

2 股票市场价值预测

本章将详细阐述股票市场价值预测理论和机器学习方法在股票市场的应用。本章共分为三个小节。第一小节会介绍股票市场价值预测的基础概念，给出股票预测相关的时间序列预测定义；第二小节将详细介绍支持向量回归算法^{[21][23]}、随机森林算法^{[16][24][31]}以及人工神经网络算法^{[15][18]}的方法原理；第三小节将介绍各种机器学习方法预测股票市场价值效果的评价指标，给出定义并介绍其应用，帮助我们对比分析不同的机器学习方法在股票市场的实际预测效果。

2.1 股票市场价值理论

为了下文展开股票市场价值预测内容，我们将价格预测问题转为时间序列预测问题^[26]。进行如下定义：


股票市场价值由以相等时间间隔测量的时间顺序数据点的离散序列组成。给定 ε 和一组 n 个样本，其特征为 T 个实值 $X_1, \dots, X_T, (1 \leq i \leq T)$ 。 X_i 表示在时间 i 上的记录值，设 w 为历史窗口长度， h 为预测范围，且 $w+h \leq T$ 。然后，相关的时间序列预测问题可以表述为，给定 $X_1, \dots, X_w (w+h \leq T)$ ，预测 $X_{w+1}, \dots, X_{w+h}$ ，目的是最小化预测值 $\hat{X}_{w+i}$ 和实际值 $X_{w+i} (1 \leq i \leq h)$ 之间的误差。

2.2 机器学习预测模型

2.2.1 支持向量回归

基于奥卡姆剃刀原理，统计学家 Vapnik (1995) ^[12] 构建了结构风险最小化理论 (SRM)，在对目标的求解和优化过程中，融入对模型复杂性的考虑，而不是像以往的经验风险最小化理论 (ERM) 那样，仅仅只是追求与现有数据的完美拟合，而不考虑其计算效率，并提出了支持向量机模型。支持向量机模型 (SVM) 实质上就是对数据进行二元分类的线性分类器。与非线性回归和 ANN 模型相比，支持向量机在解决复杂的非线性问题时具有更好的效果。

支持向量机的主要思想是构造一个超平面作为决策面，使正、负样本的间距最大。对于一个二分类问题，假设有一组输入向量 $x_i \in R^d (i=1, 2, \dots, N)$ ，对应的标签为 $y_i \in \{+1, -1\} (i=1, 2, \dots, N)$ 。其目标是构造一个二元分类器，通过现有数据样本推导出一个决策函数，且该函数对未来的数据样本进行错误分类的概率很小。SVM 通过引入核函数实现高维特征空间中的内积运算。为了构造最优超平面，我们将输入向量 $x_i \in R^d$ 投



映射 $\Phi(\cdot)$ 由核函数 $K(x_i, x_j)$ 决定。 $K(x_i, x_j)$ 定义了空间 H 中的内积。引入核函数后, 我们就可以将构造最优超平面的问题表示为下面的形式:

$$\begin{aligned} \max W(a) = \max \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j \cdot y_i y_j \cdot K(x_i, x_j) \\ \text{s.t.} \quad \begin{cases} \sum_{i=1}^N \alpha_i y_i = 0 & i=1, 2, \dots, N \\ 0 \leq \alpha_i \leq c \end{cases} \end{aligned} \quad (2-1)$$

$$f(x) = \text{sgn} \left(\sum_{i=1}^N y_i \alpha_i \cdot K(x, x_i) + b \right) \quad (2-2)$$
$$K(x_i, x_j) = (x_i \cdot x_j + 1)^d \quad (2-3)$$

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2} \quad (2-4)$$

7

支持向量回归(SVR)是支持向量机(SVM)的一种变体, 适合用于回归和预测任务。如上文所述, 最初, SVM 是为了解决模式识别问题而发展起来的, 是针对广义肖像算法 (Generalized Portrait Algorithm) 的分类器。而后, 人们进一步在模式识别中去推广回归预测, 便发展出了 SVR。SVR 是在做数值拟合时, 引入了拉格朗日乘子, 并且采用了支持向量的思想, 在回归情况下引入 ϵ 不敏感损失函数, 这样它相对于经典且基础的最小二乘法, 有了很大的优势, 比如可以更好地处理非线性拟合、多重共线性情况等。在处理高维空间中大规模数据时, 决策函数的构造很关键, 一般在分类问题中, 人们会比较少的支持向量来设置决策函数, 这样是为了让解具有稀疏性, 对于大规模数据来说, 处理的高效很重要。SVM 基于分类, SVR 基于回归, 他们相似地都用到了支持向量, 很多处理过程相似, 但是一些细节的不同也存在。

支持向量机(SVM)本身是针对二分类问题所提出的, 而支持向量回归(SVR)是支持向量机中的一个重要的应用分支。SVR 回归与 SVM 分类方法的主要不同点在于, SVR 的样本点最终只有一类, 它所寻求的最优超平面, 是想让样本点尽可能的放到这个超平面上, 所以需要样本点到超平面的总误差尽可能小。而 SVM, 是要找一个超平面把两个类别的物体尽可能的分开, 所以需要所有样本点到超平面的距离尽可能大。如图 2-2 所示, SVM 是要使到超平面最近的样本点的距离最大, SVR 则是要使最远的那个样本点到最优超平面的距离最小。




图 2-2 SVM 与 SVR 示意图

由于实际输出是一个实数、而不是一个范围, 因此很难预测一个确切的值, 因为它有无限的可能性。然而 SVR 与 SVM 的主要思想是相同的: 最小化误差, 在满足设定的误差范围内, 找到最大化边际的超平面。SVR 采用了 SVM 的一个核心思想——面对线性不可分的情形, 采用非线性映射算法将低维映射高维度空间, 让线性不可分的低维数据变成线性可分的, 然后在高维空间对数据进行回归分析。SVR 模型的优点在于, 它对数据的形式没有过多要求, 因此可以有效解决小样本问题、非线性问题及高维度问题。SVR 模型可以被表示为:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N (\xi_i + \hat{\xi}_i)$$

$$s.t. \quad \begin{cases} y_i - f(x_i) \leq \varepsilon + \xi_i \\ f(x_i) - y_i \leq \varepsilon + \hat{\xi}_i \\ \xi_i \geq 0, \hat{\xi}_i \geq 0 \end{cases} \quad (2-5)$$

其中, $f(x_i) = w'x_i + b$, ξ_i 和 $\hat{\xi}_i$ 是松弛因子。

SVR 允许预测值和真实值之间存在合理的误差, 即 $|y_i - f(x_i)| \leq \varepsilon$ 。根据 Lagrange 函数的对偶性和极小值求解的方法, 可以得到 $f(x_i)$ 中参数 w 与 b 的值:

$$\begin{cases} w = \sum_{i=1}^n (\alpha_i - \hat{\alpha}_i) x_i \\ b = y_i + \varepsilon - \sum_{i=1}^n (\alpha_i - \hat{\alpha}_i) x_i x_j \end{cases} \quad (2-6)$$

其中, α_i 和 $\hat{\alpha}_i$ 是拉格朗日乘子。

对于非线性问题, 为了使 SVR 模型也能有很好的适用性, 引入核函数 $K(x_i, x_j)$ 替换高维空间的内积, 此时函数 $f(x_i)$ 可表示为:

$$f(x_i) = \sum_{i=1}^n (\alpha_i - \hat{\alpha}_i) K(x_i, x) + y_i + \varepsilon - \sum_{i=1}^n (\alpha_i - \hat{\alpha}_i) K(x_i, x_j) \quad (2-7)$$

2.2.2 人工神经网络

人工神经网络算法是用于分类和回归的计算模型。它受到了人类大脑神经网络的启发。一个神经网络由一组相互连接的节点组成, 这些节点被称为神经元, 它们模拟大脑的结构相互连接。信息在神经元之间传递, 通过训练数据来实现学习过程。1943 年, McCulloch-Pitts 神经元由皮特斯和麦卡洛克提出, 这是第一个人工神经元的学术来源, 两位学者是为了对脑功能中的神经活动进行建模。后来学者们继续进行了研究, 比如有冯·诺伊曼的数字计算机, 到了 20 世纪 50 年代, 马文·明斯基提出感知机模型, 这也是第一个可以根据不同类别输入的样本来不断学习权重的模型。随后不久, 自适应线性单元也出现了。近年来, 深度学习发展趋势迅速, 已成为人工智能研究的重要领域之一, 在信号处理、视觉数据处理和非线性问题优化等方面取得了重大进展。生物神经网络为其提供了技术原型, 神经网络是由大量的神经元广泛连接的一个网络结构。我们可以将 ANN 的特性归纳为: 结构特性和能力特性。其中, 结构特性是指其具有并行能力、可以分布式存储以及具有很高的容错性, 而能力特性是指 ANN 算法具有自学习与自适应性的能力。

神经网络由不同的层组成: 输入层、一个或多个隐藏层和一个输出层。不同层节点之

间的连接是加权的,信息通过激活函数从一层传递到另一层,激活函数解释了数据中的非线性关系。这个过程称为前馈传播,它定义了如何将数据反馈到下一层。人工神经网络模型使用最小化损失函数进行监督训练学习,最小化损失函数通过调整不同神经层之间的连接权值来计算预测误差。最终在输出层计算预测结果,在最后一步中使用转换函数。输入层神经元的数量是变化的,其取决于输入数据的维数,而输出层神经元的数量则取决于预期输出结果。

在众多神经网络算法模型中,最广为应用的便是 BP 神经网络算法,最常见的 BP 神经网络模型一般是一个三层的网络结构,同样包括:输入、隐藏和输出层。作为前馈神经网络的核心,BP 模型被广泛地使用与应用于很多实例问题。

BP 算法将人工神经网络的监督学习训练过程分为两个程序:

(1) 信号正向传播过程:输入样本从输入层传入,经各隐藏层逐层处理后,传向输出层。如果输出层的计算结果与预期输出不符,就进入误差的反向传播过程。

(2) 误差反向传播过程:将输出结果通过神经网络的隐藏层,向输入层逐层反传,并将得到的误差分配给途径各层的所有单元,获得各单元的误差信号,将计算出的误差信号当作修正人工神经网络结构各单元权重值的参考指标。

激活函数存在于隐藏层神经元和输出层神经元的内部。BP 神经网络常使用 Sigmoid 激活函数来增加模型的非线性拟合能力。利用 Sigmoid 函数可以实现数据由输入到输出的非线性映射。Sigmoid 函数分为 Log-Sigmoid 和 Tan-Sigmoid 两种,分别定义如下:

$$f(x) = \frac{1}{1+e^{-x}} \quad (2-8)$$

$$f(x) = \frac{1-e^{-x}}{1+e^{-x}} \quad (2-9)$$

BP 神经网络的具体步骤如下:

(1) BP 网络及学习参数初始化,即将隐藏层和输出层各节点的连接权重、神经元阈值等参数设定为合适的值。设 BP 神经网络的输入和输出分别 $X(x_1, x_2, \dots, x_n)$, $Y(y_1, y_2, \dots, y_n)$, 输入值和输出变量决定了网络的结构,即输入层、隐藏层和输出层的节点,分别将其设为 n, l, m 。设输入层和隐藏层之间神经元权重为 w_{ij} , 设中间层和输出层之间的连接权重为 w_{jk} , 设中间层阈值为 a , 输出层阈值为 b , 将上述参数都初始化。设定激活函数 Sigmoid。

(2) 隐藏层输出计算。设隐藏层输出为 H , 则:

$$H_j = f\left(\sum_{i=1}^n w_{ij}x_i - a_j\right) \quad j=1,2,\dots,l \quad (2-10)$$

(3) 输出层结果计算。设 BP 网络结构的预测值为 O , 则:

$$O_k = f\left(\sum_{j=1}^l H_j w_{jk} - b_j\right) \quad k=1,2,\dots,m \quad (2-11)$$

(4) 结果误差计算。设误差为 e ,

$$e = Y_k - O_k \quad k=1,2,\dots,m \quad (2-12)$$

(5) 根据误差值, 逐层修正各层之间的连接权重及阈值

$$w_{ij} = w_{ij} + \eta H_j (1 - H_j) x(i) \sum_{k=1}^m w_{jk} e_k \quad i=1,2,\dots,n \quad j=1,2,\dots,l \quad (2-13)$$

$$a_j = a_j + \eta H_j (1 - H_j) x(i) \sum_{k=1}^m w_{jk} e_k \quad j=1,2,\dots,l \quad (2-14)$$

$$b_k = b_k + e_k \quad k=1,2,\dots,m \quad (2-15)$$

(6) 反复执行上述过程, 直到满足预期的输出模式。

2.2.3 随机森林

(1) 决策树

决策树是经典的机器学习模型, 是用树形图来表示逻辑处理的一种工具, 由一系列节点和分支组成。一般从根节点开始, 通过一系列结点和分支组成。在决策树中, 有以下两种类型的结点: 非叶节点和叶节点。

在决策树中, 每条边对应着一个判定条件。决策树的基本原理是, 从根节点开始, 走不同的路径, 完成根节点通过非叶节点到每个叶结点的判定测试。然后叶节点的类别就是这个样本被判断的类别。决策树优点很多, 比较显著的有计算复杂度较低、属于有监督学习和决策方式类人等。

(2) Bagging

Bagging 是一种通过 bootstrap 取样方法, 构造出多个模型, 希望可以降低泛化误差的技术。具体的思路就是对于每个训练集, 分别训练出不同的模型, 并且让这些模型都对测试集的输出进行表决, 然后将他们结合起来得到最终的 bagging 模型。我们可以将 bagging 分为 bootstrap 取样和模型聚合。

bootstrap 取样是有放回的重复取样, 一般情况下, 新得到的 n 个样本中定都有重复样本, 也必有原来数据集中的样本没有被取到。在这种取样中, 取到原数据集是一种很极端的情况。我们假设每个数据集中样本被取出概率相同, 在 bagging 取样中, 对于原训练集, 当我们使用 bootstrap 取样 m 次, 就会选出 m 个 bootstrap 伪样本集。在每个被抽出的 bootstrap 伪样本集上, 构建相应的基学习器, 每个 bootstrap 伪样本集所含样本的差异性就会导致训练模型之间的差异, 从而我们可以得到 m 个不同的学习器。

(3) 随机森林

随机森林是一种集成方法，是 bagging 的一个实际应用算法，可应用于分类和回归任务。在训练模型时采用单个决策树经常会使训练集过度拟合。数据中的微小噪声可能会使决策树具有很高的方差和很低的偏差，导致决策树变成完全不同的结构。而随机森林算法使用了 bagging 的基本思想，通过训练在特征空间的不同子空间上的多个决策树，以增加偏差为代价，克服了单个决策树的缺陷。这也意味着随机森林中任意一个决策树都不能覆盖到全部训练集。

随机森林预测模型由一组决策树构成，最终的预测需要考虑每棵树的结果，在分类的情况下采用多数表决，这个结果会被随机森林当成最后的结果。对于回归的情况，随机森林的预测结果一般是多个决策树结果的加权平均得到的。该模型会进行随机抽样，对抽样的数据样本进行独立训练，得到一棵决策树。随机森林方法最初由 Ho 提出，随后 Breiman 对其就随机子集方法与 bagging 方法相结合进行了相应的改进。随机森林算法提供了一种以较低的方差平均多棵树的方法，因为每棵树都是由数据和特征的随机子集组成的。标准随机森林分析流程如图 2-3 所示。该流程的重要参数有：决策树的数量以及每个决策树所使用的特征数量。




图 2-3 随机森林构造

2.3 评价指标

为了检验三种模型的预测效果，便于对比，我们选取六种指标进行评价，分别是最大误差、最小误差、平均绝对误差、均方根误差、平均绝对百分比误差和对称平均绝对百分比误差。

(1) 最大误差

预测范围内，预测值与真实值之间的最大误差。

$$E_{\max} = \max \{y_t - \hat{y}_t\} \quad t = 1, 2, \dots, n \quad (2-16)$$

(2) 最小误差

预测范围内，预测值与真实值之间的最大误差。

$$E_{\min} = \min \{y_t - \hat{y}_t\} \quad t = 1, 2, \dots, n \quad (2-17)$$

(3) 平均绝对误差

均方误差是预测值和真实值之间绝对误差的平均值。

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad (2-18)$$

MAE 实质上是一种线性分数，离群值可能会影响最终结果。

(4) 均方根误差

均方根误差是预测值与真实值之间残差的样本标准差。

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (2-19)$$

(5) 平均绝对百分比误差

绝对误差与真实值的百分比。

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad (2-20)$$

MAE 是模型产生的平均误差幅度，而 MAPE 表示预测值与实际值之间的平均距离。与 MAE 相比，MAPE 受异常值存在的影响较小。

(6) 对称平均绝对百分比误差

它是平均绝对百分比误差 MAPE 的一个改进指标，解决了 MAPE 由于分母为零而导致计算结果无穷大或无定义的问题。

$$sMAPE = \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{|y_t + \hat{y}_t|/2} \quad (2-21)$$

3 股票市场技术分析策略

本章将详细阐述技术分析基础理论、技术分析指标、MACD 择时策略、混合机器学习与技术分析策略以及评价指标。本章共分为五个小节。第一小节会分析技术分析有效性，详细介绍技术分析理论；第二小节将介绍指数移动平均线和指数平滑异同移动平均线，并给出定义；第三小节将介绍 MACD 择时策略理论及策略定义；第四小节将详细介绍混合技术分析策略构建流程以及混合策略的定义；第五小节将介绍技术分析策略的评价指标。

3.1 技术分析基础理论

3.1.1 技术分析有效性

为了证明优化的技术分析策略在我国股票市场的适用性，在介绍本文所使用的技术分析理论之前，有必要对上文提到的技术分析有效性进行进一步的展开讨论，我们将从有效市场假说的提出以及相关金融市场学理论的发展开始分析。

有效市场假说(EMH)是指市场中所有可能影响股票涨跌的因素都能及时反映在股票涨跌上面，股票价格已经反映所有可用信息。该假说的基本前提是：投资者都是理性的，就算个体非理性，由于随机性，个体的非理性部分会被抵消；若个体的非理性具有一定共性，即无法完全抵消，那么由于投机者的存在、套利机会的存在也会消除非理性的行为。有效市场假说的提出者 Fama 将有效市场分为三类：

(1) 弱有效市场：指股票价格反映了一切过去的信息。这种情况下股票价格已经充分反映了过去股票价格所提供的各项信息。由于技术分析是使用历史数据预测股价未来走向，所以，以过去价格为基础的技术分析进行预测不会有利于投资、提高收益。

(2) 半强有效市场：指股票价格不但反映了股票市场所有过去的相关数据，而且还还能从中得到一切可以开源获取到的资料，比如相关企业和公司的财务报表、年报公告等信息。这意味着使用历史交易中所包含的信息或已公开的信息，都无法获得额外收益；

(3) 强有效市场：指股票价格不但反映了一切过去和公开的信息，还反映了尚未公开的信息。由于这是最高级的有效市场，所以任何手段和信息都不能使交易者获得更高的收益，这也就意味着任何消息对市场参与者来说都毫无用处。

我们从上述理论就可以看出，在有效市场假说中，技术分析无法有效提高投资者的收益，早期的研究也大都认同有效市场理论，否认技术分析的有效性。然而随着行为金融学理论的发展，传统的金融学理论受到了冲击。

行为金融学理论解决了许多过去使用传统金融学理论无法解释的问题。以美国普林斯顿大学的心理学家 Kahneman 和 Tversky 为代表的学者认为在现实中,金融股票市场的参与者投资者们并不像有效市场假说定义中的完全理性,真实的人不会按照简单的概率做出选择,他们会通过自己所观察和学习到的模式和经验进行选择,比如遇到股价上涨时,即使他们知道股价总会回落,但是他们会期望上涨的趋势会一直持续,而且这种认知偏差并不是个体性的,而是具有群体共性的,基于这种现象,展望理论也由此提出。随后行为金融学研究也逐渐兴起,但是行为金融学并未形成系统化的理论和模式,因此一定程度上也无法有力冲击和取代有效市场假说的核心地位。而之后的适应性市场假说的提出,才真正改变了这个现状。

适应性市场假说(AMH)是指金融股票市场的参与者就像大自然的生物进化过程一样,处于不断学习和优化的过程中。与市场有效性假说相比,在适应性市场假说下,价差交易机会是存在的,进化过程导致交易机会具有时变性^[22]。

适应性市场假说的提出,化解了市场有效性假说和行为金融理论的分歧,构建了一个系统化的、统一化的金融市场分析理论框架,也证明了技术分析在股票市场预测方面的有效性。

3.1.2 技术分析理论

在金融学理论中,对于股票市场的投资研究存在两种分析方法:基本面分析法和技术分析。本文采用技术分析方法来研究股票市场。技术分析利用过去的股票市场数据,将其转换成图表或者指标数据的形式,通过预测股价走势,帮助投资者判断提高收益。技术分析基于股票市场历史统计数据(日期、历史开盘价、历史收盘价、历史最高价、历史最低价、交易量等),对股价交易机会和交易策略进行识别和评估。该方法可以基于历史交易数据研究期权、股票等债券资产。技术分析理论认为过去的资产价格变化和交易行为对于未来价格走势的预测是非常重要的。

当代技术分析的理論最早可以追溯到 19 世纪末—20 世纪初,由查尔斯·道提出的“道氏理论”。该理论的假设为:市场行为中已经包括所有信息,股票价格波动体现了所有对证券市场产生影响的因素;证券价格沿一定趋势移动,其运动方向是由供求关系决定的;历史会重演,而在证券市场中,投资者的行为也会受到心理学规律的影响,可以通过历史信息,在一定程度上预测未来。根据上面的假设可知,技术分析的核心观点是根据发现的股价波动规律,分析理论,设计指标体系,实现对现实交易的指导作用。

与基本面分析法相比,技术分析法对于择时择股的研究更具有现实指导意义,它可以更好地把握买进和卖出的关键节点,与此同时,针对不同的行情走势,技术分析的指标及参数选择也十分重要,不同的分析指标和参数会导致不同的策略收益效果。随着技术分析体系的发展,近年来学者们也都提出了很多技术指标,这些指标分为两大类:

(1) 趋势跟随: 趋势跟随也称为动能效应, 指做多过去一段时间表现最好的品种。金融市场趋势可以用羊群效应, 即从众跟风效应解释, 当股票市场向好, 股价大幅上涨或者存在明显上涨趋势时, 会吸引更多的投资者进行市场交易, 而随着市场交易行为的增多, 另一方面也会推动股票价格继续上涨。行为金融学用“反应不足”来解释动能效应, 投资者对新信息的反应不足导致价格向某一个方向持续运动, 即便基本面已经发生变化, 投资者仍然没有做出改变。通常情况下, 动能效应可以分为两种, 一种是时间序列动能, 另外一种为横截面动能。常用指标有移动平均线(MA), 指数移动平均线(EMA), 抛物线转向(SAR)等。

(2) 均值回归: 主要思想是价格会向长期均值回归。当价格过度上涨, 策略要求做空, 当价格过度下跌时, 策略要求做多。这个策略既可以用于短期, 也可以用于长期。常用指标有随机指标(KDJ), 威廉指标(WR)等。

3.2 技术分析指标

3.2.1 指数移动平均线(EMA)

移动平均线(MA)是一种常用的技术分析工具, 通常用于确定股票的趋势方向或确定其支撑位和阻力位。这是一个趋势跟踪或滞后指标, 因为它是基于过去的价格计算的, 虽然MA不能预测新的趋势, 但是它可以确定趋势的方向。指数移动平均线(EMA)就是移动平均线的一种, 它赋予近期价格更多的权重, 以使其对新信息的反应更快。EMA通过对给定时间段 m 的价格进行平均, 过滤掉随机价格波动的噪音, 使价格变得平滑。其定义如下:

$$EMA_t^m(S_t) = \begin{cases} S_t & \text{if } t=1, \\ \alpha \cdot S_t + (1-\alpha) \cdot EMA_{t-1}^m & \text{if } t>1. \end{cases} \tag{3-1}$$

上式中, S_t 为当前价格, m 为观测次数, α 为平滑因子, $\alpha = \frac{2}{m+1}$ 。

3.2.2 指数平滑异同移动平均线(MACD)

该指标最早由美国投资家 Gerald Appel 于 20 世纪 70 年代末提出, 是最为有效可靠的指标之一。MACD 指标的原理是基于移动平均线的思想, 使股票价格曲线更平滑、求出其加权平均值后的一种技术分析趋势跟随类指标^[8]。它利用短期移动平均线和长期移动平均线之间的相交及相离情况, 对股票买进及卖出的时机进行判断。普通移动平均线具有产生交易信号过于频繁的缺点, 而 MACD 策略则对此进行了改善, 它增加了发出

信号的要求和限制，在实际操作中比移动平均线更为稳定。另一方面，MACD 依据近期的均线趋势性，判断上涨或者下跌行情的开始与结束，适合研究判断中长期的股票走势。

MACD 通过使用滞后性的均线指标，来显示趋势的特征。趋势方向和趋势的持续时间是通过计算两个 EMA 之间的差值来确定的。当用长期移动平均线减去短期移动平均线后，我们就可以得到震荡指标，构造了在零点线上下摆动的震荡线，并且没有上下幅度限制。MACD 包括:DIF 线和 DEA 线。

DIF 线是短期均线与长期均线之间的差值。DEA 线是 DIF 指标在一定时间内的平均值。给定时间周期为 m, n 和 p 使得 $m < n$ ，那么

$$DIF_t = EMA_t^m(S_t) - EMA_t^n(S_t) \tag{3-2}$$

$$DEA_t = EMA_t^p(MACD_t) \tag{3-3}$$

3.3 MACD 择时策略

作为技术分析交易策略，本文选择了基于 MACD 和 EMA 指标的 MACD 策略。
该策略定义如下：

$$Strategy_{t+1} = \begin{cases} Buy & \text{if } DIF_t > DEA_t, \\ Sell & \text{if } DIF_t < DEA_t. \end{cases} \tag{3-4}$$

当 DIF 穿过 DEA 上方时，这表示股价强势，行情看涨，就会产生一个潜在的买入信号；当 DIF 向下穿过 DEA 时，这表示股价弱势，行情看跌，会产生一个潜在的卖出信号。

3.4 混合机器学习与技术分析策略

3.4.1 混合技术分析策略构建流程

该策略旨在通过在技术分析交易规则中加入机器学习预测趋势指标来改善技术分析交易信号。总体方案如图 3-1 所示。




图 3-1 混合策略回溯流程图

首先，从服务器收集股票数据，然后将数据分割成训练集和测试集。训练数据用于优化机器学习预测模型和 MACD 策略。基于选择出的最优机器学习方法和最优 MACD 参数，构建混合模型，并在测试数据集上评价其效果。最后，对结果进行分析，评价该混合策略的效果。这个流程的主要步骤是：

(1)建立最优学习模型。

对时间序列进行预处理，使用前向验证的策略。设置历史窗口数量 w 和预测范围 h 。给定训练时间序列的观测数据和 w 、 h 的值，训练监督学习数据是通过考虑大小为 $w+h$ 的滑动窗口创建的。第一个训练集由 x_1 到 x_{w+h} ，共 $w+h$ 个观测值组成，对于第下一个训练集，这样的窗口将从 x_2 滑动到 x_{w+h+1} ，以此类推。这个过程如图 3-2 所示。




图 3-2 数据集划分过程

(2) 优化技术分析策略。

在这一步中，训练数据用于回测技术分析策略。为此，对整个训练数据应用网格搜索。在测试过程中选择性能最好的参数进行混合策略的构建。

(3) 回测混合技术分析策略。

对混合技术分析策略进行回测。在最后一步中，混合策略将在测试数据集上进行回测，对提出的混合交易策略进行评价。

3.4.2 混合策略规则

MACD 均线属于滞后指标族，是滞后于当前市场价格的可衡量因素。它不仅可以用来产生交易信号，也有助于确认长期趋势的强度。此外，由于市场短期波动等因素，这类指标可能会产生虚假信号。因此，有必要对预测价格进行处理，减少错误信号。

该规则使用预测模型生成交易信号。对于给定的 t 日， Buy_t 和 $Sell_t$ 指的是仅由技术分析策略给出的买入和卖出信号。而在第二章选出的最优机器学习预测模型则提供了关于未来价格变化趋势的信息。股票价格的趋势对决定买入股票或卖出股票很有帮助。

在这种情况下,为了估计市场趋势,该混合交易策略将 t 日的价格 x_t 与 $t+h$ 日的预测值 $\hat{x}_{t+h}$ 进行比较。如果 $\hat{x}_{t+h} > x_t$,则认为未来趋势为上升趋势 UT_{t+h} ;如果 $\hat{x}_{t+h} < x_t$,则认为未来趋势为下降趋势 DT_{t+h} 。

在这个策略中, t 日的买入信号是由 $t+h$ 日的上升趋势指标和技术分析指标决定的。同样地, t 日的卖出信号是由 $t+h$ 日的下降趋势指标和技术分析指标决定的。设 D_t 为 t 日的交易决策,将交易规则定义如下:

$$D_{t+1} = \begin{cases} Buy, & Buy_t \text{ 或 } UT_{t+h}, \\ Sell, & Sell_t \text{ 且 } DT_{t+h}. \end{cases} \quad (3-5)$$

3.5 评价指标

选用如下指标来评估相关交易策略的效果和收益。

(1) 盈亏比

即周期盈利亏损的比例。

$$PF = \left| \frac{\text{利润}}{\text{亏损}} \right| \quad (3-6)$$

如果 $PF < 1$,那么亏损>利润;如果 $PF > 1$,那么亏损<利润。

(2) 交易数量

完成的交易数量 $\#T$ 。一笔交易由买入和卖出指令组成。

(3) 最大回撤

表示资产组合生成收益时可能出现的最糟糕的情况,即在测试期间观察到最严重的浮动亏损,通常用来表示投资人的最大心理承受能力。

$$D_{\max} = V_h - V_l \quad (3-7)$$

其中, V_h 为账户最高价值, V_l 为账户最低价值。

(3) 净利润

损益合计。

$$NP = \text{利润} - \text{损失} \quad (3-8)$$

(4) 每笔交易平均利润

将净利润除以交易数量。

$$\bar{T} = \frac{NP}{\#T} \quad (3-9)$$

(5) 利润百分比

也被称为获胜概率,计算方法是将获胜交易的数量除以总交易数量。

$$PP = \frac{\#T_w}{\#T} \quad (3-10)$$

(6) 策略收益

$$\text{总收益} = \frac{P_e - P_s}{P_s} * 100\% \quad (3-11)$$

P_s 为执行交易策略前，投资人所持有的总资产价值， P_e 为执行交易策略后，投资人所持有的总资产价值。

(7) 基准收益率

基准收益率也被称为基准折现率，是金融市场中，企业公司或行业、投资者等从动态投资的角度出发、在投资交易过程中、可接受的最低标准的回报收益率。

(8) 夏普比率

也称夏普指数，是基金的预期绩效收益评估中的标准化比率指数。其计算公式如下：

$$SR = \frac{E(R_p) - R_f}{\sigma_p} \quad (3-12)$$

其中 $E(R_p)$ 为与投资组合预期报酬率， R_f 为无风险利率， σ_p 为投资组合超额报酬率的标准差。

4 实证分析

本章将会先在第一小节介绍实证所用数据选取过程及选取数据的概况,在第二、三、四小节以上证 50 为例进行实证分析。第二小节将使用三种机器学习模型预测未来股票价格,评价其预测效果选出最优预测模型;第三小节将计算 MACD 最优参数用于回测;第四小节将回溯测试两种交易策略,分别评价其效果;第五小节将进一步对沪深 300 和中证 500 进行实证分析。

4.1 数据的来源和选取

本文关注国内三大指数的每日指标:上证 50、沪深 300 和中证 500。上证 50 投资指数挑选上海证券市场规模大、流动性好的最具代表性的 50 支股票组成样本股,以便综合反映上海证券市场最具市场影响力的一批企业的整体情况。目前成分股中,45 只个股总市值在 1000 亿以上。在上证成分股中最重要的是茅台、招商和平安三大巨头。上证 50 指数涉及到的行业集中度很高,金融业的占比已经接近 60%,因此上证 50 指数的上涨和下跌趋势及持续时间等受金融业的影响很大、涨跌幅度也比较大。而与上证 50 相比,沪深 300 指数则全面反映了我国 A 股市场上市股票价格的整体表现,因此沪深 300 俗称“蓝筹股”。沪深 300 的行业比重是比较平衡的,在各个领域都有涉及。但是相对而言还是金融板块的比重较大,超过了 35%。其他板块都比较平衡,所以沪深 300 的走势更稳定,涨跌幅度均小于上证 50。最后,中证 500 指数是由在 A 股中剔除上证 50 指数和沪深 300 指数成份股后、总市值排名靠前的 500 只股票组成,综合反映了 A 股中小型企业市值的股票价格。所以中证 500 是偏向于中小型企业指数。因此从行业的分布来看,中证 500 指数中占比比较大的都是科技类的成长型企业,更适合投资者长线投资。这三大指数各有特点、风格和侧重不同,且收益都比较可观,可以比较全面的代表中国股市的趋势和发展,因此本文选择这三大指标进行实证分析。

本文选取三大指数 2012 年 1 月 1 日至 2021 年 12 月 30 日的每日交易数据,数据收集自 Choice 平台。2020 年初始,新冠疫情的爆发为中国经济和世界经济蒙上了一层阴影,并且新冠疫情所带来的影响是持续的、长期的,成为了至今的经济背景之一,影响极广。新冠疫情的爆发也带来了诸多不确定性,比如 2020 年初中国股票市场开盘后,沪深市场多只个股跌停,出现这样结果最主要的就是新冠疫情的影响。自疫情以来,货币政策、疫苗计划、财政政策和疫情变化等因素都对股票市场带来了剧烈影响。因此,为了客观分析研究本文提出的基于机器学习的优化股指技术分析策略,我们将实证研究

分为两个部分：疫情前阶段和疫情后阶段。对于疫情前阶段，选择 2012 年 1 月 1 日-2019 年 12 月 31 日的交易日数据进行训练验证和回测；对于疫情后阶段，选择 2020 年 1 月 1 日-2021 年 12 月 31 日的交易日数据进行训练验证和回测。

在股票预测模型部分，用以下五个输入变量进行预测：每日开盘价、每日收盘价、每日最高价格，每日最低价格和每日成交量。在实验中，每个买入或卖出指令在产生信号后第二天执行。

4.2 机器学习模型选择

本节比较了本文使用的机器学习技术，即支持向量回归 SVR、随机森林 RF 和人工神经网络 ANN 方法，以上证 50 指数为例进行计算。设定训练集初始数据量为 T 个交易日，历史窗口期为 w 个交易日，预测期为 h 个交易日。将 h 设置为 10，是它可以更好的捕捉价格的趋势，也避免了预测期过长导致的误差过大。考虑到训练效果，将 T 设置为 240，将历史窗口集长度 w 分别设定为 6, 12, 24, 48, 96, 120 天。分别使用三种机器学习方法进行模型训练和预测，计算各项误差结果输出。对于疫情前股市的分析预测阶段，在 2012 年 1 月 1 日-2019 月 12 月 31 日的交易日数据中，随机抽取二十组数据进行训练和验证，计算各方法的平均误差和标准差。对于疫情后股市的分析预测阶段，在 2020 年 1 月 1 日-2021 年 12 月 30 日的交易日数据中，随机抽取五组数据进行训练和验证，并计算各方法的平均误差和标准差。由于部分误差量级过小，为方便比较，表中所列出的 MAPE 和 sMAPE 值为实际值 $\times 10^3$ 。

在预测过程中，发现了一些问题。如表 4-1、表 4-2。其中，T_time 为抽取数据集起点，连续抽取 240 个交易日。

表 4-1 SVR 模型 $w=12$ 预测误差表

T_time	E_max	E_min	RMSE	MAE	MAPE	sMAPE
20120119	36.75	16.18	28.34	26.23	15.63	15.59
20121012	53.43	26.00	42.35	39.69	22.82	22.83
20130325	42.59	18.73	32.97	30.64	18.71	18.79
20130715	34.11	14.76	26.25	24.38	15.57	15.54
20130724	33.73	14.59	26.02	24.17	15.44	15.41
20131114	28.81	12.43	22.23	20.67	13.45	13.43
20140128	44.59	20.61	34.89	32.61	19.09	18.73
20140411	57.25	26.27	44.74	41.75	21.28	20.91
20140515	69.77	32.79	54.65	51.27	24.43	23.95
20140619	79.44	36.83	62.03	58.00	26.14	25.65

续表 4-1 SVR 模型 $w=12$ 预测误差表

20140902	114.50	48.89	88.13	81.41	32.23	31.96
20140903	114.67	49.06	88.30	81.59	32.28	32.01
20141021	131.71	57.48	101.93	94.53	37.59	37.35
20150504	109.03	44.22	83.24	76.46	30.45	30.66
20150715	78.67	35.11	61.16	56.76	24.84	24.97
20150907	55.88	23.98	42.83	39.55	17.87	17.87
20160728	31.00	14.46	24.12	22.62	9.72	9.70
20160901	31.39	13.93	24.22	22.55	9.50	9.48
20170620	52.33	22.08	40.33	37.37	13.19	13.21
20180822	70.40	29.61	54.04	49.70	18.91	18.86

表 4-2 SVR 模型 $w=24$ 预测误差表

T_time	E_max	E_min	RMSE	MAE	MAPE	sMAPE
20120119	52.33	7.32	33.11	28.07	16.64	16.67
20121012	87.95	15.42	55.94	47.75	27.46	27.48
20130325	68.45	11.21	43.04	36.58	22.53	22.41
20130715	53.41	7.62	32.97	27.69	17.60	17.66
20130724	51.99	7.50	32.13	27.02	17.18	17.24
20131114	46.37	6.62	28.55	23.91	15.55	15.58
20140128	78.82	12.19	48.88	41.05	22.89	23.31
20140411	99.39	15.55	61.88	52.05	25.68	26.10
20140515	124.18	19.85	77.36	65.32	30.16	30.69
20140619	145.35	26.60	92.17	79.14	34.21	34.79
20140902	197.60	33.50	125.39	107.37	41.88	42.14
20140903	198.74	33.59	126.32	108.21	42.20	42.44
20141021	233.16	36.96	145.08	122.85	48.24	48.17
20150504	181.91	23.96	110.60	91.53	37.76	37.02
20150715	128.88	17.17	76.57	62.49	28.32	27.88
20150907	92.72	14.29	57.48	48.18	21.92	21.81
20160728	48.61	7.83	30.21	25.65	10.95	10.98
20160901	51.79	8.19	32.17	27.27	11.39	11.43
20170620	94.81	14.96	57.91	48.64	17.15	17.14
20180822	110.22	16.78	68.95	58.79	22.14	22.23

以上证 50 使用 SVR 模型、历史窗口长度为 12 和 24 个交易日的预测结果为例，对于不同长度的历史窗口，可以发现 2014 到 2015 年的一段时间预测结果都非常不理想，各项误差较大。当 $w=12$ ，数据集范围为 2014 年 10 月 21 日到 2015 年 10 月 14 日时，最大误差高达 131.71，最小误差也达到了 57.48；当 $w=24$ 时，数据集范围为 2014 年 10 月 21 日到 2015 年 10 月 14 日时，最大误差高达 233.16，最小误差也达到了 36.96。经

过查阅真实数据资料发现, 2015 年期间发生了持续时间长、股市波动剧烈且异常的股灾事件, 这就导致了预测模型失效, 各项误差指标都很高。因在下文计算各方法误差指标平均值及标准差时, 都剔除了异常预测数据。输出结果见下表。

表 4-3 疫情前上证 50 预测误差表

w	Matric	SVR	RF	ANN
6	E_max	33.39±11.07	27.82±9.13	1988.11±394.54
	E_min	17.99±6.11	13.81±4.42	1968.68±391.48
	RMSE	27.48±9.17	22.55±7.28	1978.57±392.95
	MAE	25.69±8.58	20.82±6.73	1978.63±393.00
	MAPE	12.68±3.39	10.26±2.58	995.62±0.97
	sMAPE	12.64±3.36	10.23±2.57	1982.52±3.60
12	E_max	50.01±16.83	41.34±13.36	1987.86±395.87
	E_min	22.40±7.78	13.28±4.18	1954.27±390.86
	RMSE	38.82±13.16	30.00±9.56	1971.17±393.29
	MAE	36.12±12.25	26.82±8.59	1971.22±393.25
	MAPE	17.91±4.96	13.26±3.30	994.05±1.28
	sMAPE	17.81±4.87	13.18±3.26	1976.28±4.85
24	E_max	79.33±27.53	59.36±19.20	2016.43±414.70
	E_min	12.17±4.26	7.28±2.52	1903.32±398.80
	RMSE	49.14±16.76	35.71±11.51	1961.35±406.90
	MAE	41.36±13.95	29.54±9.53	1960.37±407.18
	MAPE	20.50±5.71	14.67±3.74	992.07±1.60
	sMAPE	20.57±5.75	14.56±3.71	1968.64±6.16
48	E_max	131.56±48.04	95.28±31.37	2055.80±440.5
	E_min	9.09±3.90	4.71±1.83	1862.34±410.13
	RMSE	70.39±25.97	47.00±15.87	1957.20±424.54
	MAE	57.44±21.39	36.97±12.66	1955.62±423.02
	MAPE	28.49±8.95	18.48±4.82	990.03±1.90
	sMAPE	28.64±9.00	18.46±4.83	1960.23±7.44
72	E_max	160.64±59.30	119.37±43.67	2099.39±465.33
	E_min	5.08±2.23	3.22±1.32	1849.22±416.43
	RMSE	75.29±28.97	52.51±19.90	1967.48±441.40
	MAE	59.08±23.76	40.19±15.47	1965.68±441.14
	MAPE	29.44±9.81	20.06±5.90	989.20±2.22
	sMAPE	29.36±9.60	20.04±5.89	1957.38±8.57
96	E_max	184.39±70.48	137.70±55.25	2122.82±476.33
	E_min	5.35±2.13	2.59±1.19	1826.81±411.37
	RMSE	85.18±34.36	56.40±22.94	1967.67±444.37
	MAE	67.17±28.36	42.63±17.56	1965.49±443.87
	MAPE	33.48±11.43	21.23±6.60	989.23±2.24
	sMAPE	33.43±11.14	21.20±6.63	1957.36±8.84

续表 4-3 疫情前上证 50 预测误差表

120	E_max	204.20±72.53	143.49±63.05	2086.98±451.17
	E_min	4.60±2.66	2.00±0.83	1764.95±397.36
	RMSE	94.83±35.10	55.52±23.90	1910.07±425.92
	MAE	75.05±28.30	41.53±17.42	1907.75±425.63
	MAPE	39.23±13.09	21.49±7.22	989.04±2.13
	sMAPE	38.94±12.42	21.45±7.17	1956.47±8.62

表 4-4 疫情后上证 50 预测误差表

w	Matric	SVR	RF	ANN
6	E_max	54.12±2.46	47.01±2.18	3385.67±153.97
	E_min	28.64±1.70	22.19±1.26	3353.31±152.56
	RMSE	44.32±2.11	37.67±1.57	3369.96±152.95
	MAE	41.38±2.03	34.80±1.31	3369.43±153.02
	MAPE	12.23±0.60	10.30±0.38	997.72±0.11
	sMAPE	12.21±0.58	10.25±0.38	1990.84±0.44
12	E_max	81.81±2.81	73.47±3.49	3396.58±160.01
	E_min	34.91±1.39	23.39±0.37	3340.07±158.00
	RMSE	62.78±2.23	53.78±2.36	3368.49±159.01
	MAE	58.22±2.12	48.41±1.84	3368.28±158.21
	MAPE	17.27±0.95	14.29±0.32	996.67±0.19
	sMAPE	17.20±0.89	14.33±0.29	1986.51±0.93
24	E_max	122.89±5.26	97.05±4.82	3465.10±165.34
	E_min	17.37±1.08	12.51±1.33	3290.21±159.92
	RMSE	76.28±2.96	58.50±3.39	3379.65±161.11
	MAE	63.90±2.53	48.73±3.06	3378.79±161.10
	MAPE	18.71±0.71	14.33±0.53	995.70±0.10
	sMAPE	18.79±0.78	14.38±0.53	1982.56±0.98
48	E_max	214.33±12.06	146.68±5.65	3548.96±183.32
	E_min	11.40±1.01	8.54±0.96	3233.74±169.63
	RMSE	112.94±6.81	73.64±4.50	3389.51±172.72
	MAE	89.06±5.77	59.47±4.64	3387.81±172.66
	MAPE	25.99±1.53	17.42±0.79	994.43±0.27
	sMAPE	26.11±1.59	17.42±0.76	1977.66±1.13
72	E_max	279.68±10.16	182.22±14.03	3622.88±200.82
	E_min	11.29±1.66	5.67±0.92	3195.15±184.03
	RMSE	131.30±7.96	81.95±7.93	3400.35±181.47
	MAE	104.18±8.72	64.12±7.12	3397.73±181.57
	MAPE	30.08±1.51	18.62±1.37	993.99±0.35
	sMAPE	30.34±1.54	18.61±1.37	1976.07±1.49

续表 4-4 疫情后上证 50 预测误差表

96	E_max	361.15±10.04	217.80±24.19	3682.64±204.79
	E_min	8.53±0.83	4.59±0.72	3161.00±199.23
	RMSE	157.13±4.72	88.62±10.93	3409.95±182.92
	MAE	121.44±6.64	68.35±9.14	3406.44±183.16
	MAPE	34.89±0.70	19.77±1.86	994.03±0.36
	sMAPE	35.33±0.65	19.78±1.91	1976.26±1.28
120	E_max	431.08±31.26	248.29±21.66	3743.03±191.27
	E_min	6.90±0.23	4.13±0.59	3125.98±214.74
	RMSE	191.22±19.07	91.84±10.54	3434.60±155.91
	MAE	146.91±14.00	69.55±8.97	3430.50±156.62
	MAPE	41.90±5.44	19.97±1.92	994.10±0.25
	sMAPE	42.87±5.96	19.96±1.89	1976.54±1.14

通过计算结果发现，总体来说，随机森林算法表现较好，支持向量回归算法次之，但支持向量回归算法对内存和运算速度要求较大。人工神经网络算法无法收敛。当 $w=6$ 时，各项误差最小，随着 w 的逐渐增大，各项误差也逐渐增大。理论上讲模型精度应随着历史窗口 w 的长度增大而增大，但是对于股票市场， w 增大意味着现实中可能受到各种因素影响的概率就变大，从而会影响预测效果。

对比疫情前后的各项误差输出表，我们可以明显发现，疫情后的预测误差，与疫情前预测误差相比，对于不同长度的历史窗口 w ，均有所增加，这就是疫情及社会形势带来的不确定性导致的。另外，疫情后的预测标准差小于疫情前标准差，这是因为疫情后阶段时间较短，数据集仅有两年，且只从中随机抽取五组数据集进行训练预测，数据集之间高度重合；而疫情前随机抽取 2012-2019 八年间的的历史数据，数据集较为分散，以及我国经济和股票市场在 2012-2019 年迅速发展，时间跨度较长，因此导致了标准差较大。

最后，考虑到是否因预测范围 h 设置问题或数据未归一化导致人工神经网络算法效果不好，因此对于疫情前后各抽一组数据集测试 $w=3$ ， $h=1$ 时的各项误差，结果如表 4-5 所示：

表 4-5 预测误差表

时间	Matric	SVR	RF	ANN
疫情前	E_max	122.88	117.86	283.35
	E_min	1.18	2.08	0.20
	RMSE	56.88	45.78	56.19
	MAE	44.26	31.25	39.56
	MAPE	71.45	51.71	159.41
	sMAPE	74.41	53.03	159.08

续表 4-5 预测误差表

疫情后	E_max	37.79	44.29	74.52
	E_min	0.16	1.94	0.30
	RMSE	19.70	22.09	21.88
	MAE	16.05	17.83	18.91
	MAPE	34.01	38.42	46.30
	sMAPE	34.12	37.61	46.89

由上述结果可以看出，即使当 $h=1$ 时，对比各种误差指标，人工神经网络算法的误差也都大于另外两种算法。

4.3 MACD 策略参数优化

为了在混合技术分析策略中得到最佳收益，对于疫情前后阶段，分别使用策略回测期前一年的数据，即 2018 年 1 月 1 日到 2018 年 12 月 31 日，2020 年 1 月 1 日到 2020 年 12 月 31 日的每日交易数据进行网格搜索，寻找最优参数值。下表给出了 MACD 策略所考虑的参数值范围。

表 4-6 MACD 交易策略考虑的参数范围

参数	范围
短期	[3,10]
长期	[6,30]
中期	[8,12]

经过回测，最佳效果参数组合前 10 名见表 4-7、表 4-8。

表 4-7 MACD 策略 2018 上证 50 参数值结果 top10

Short	Long	Mid	PF	#T	NP	T_bar	PP	D_max
3	6	10	1.352	25	201.130	8.045	0.600	261.630
3	6	9	1.216	26	115.697	4.450	0.538	308.056
10	13	8	1.133	27	91.631	3.394	0.481	263.433
3	7	10	1.044	23	25.772	1.121	0.478	410.888
3	6	8	1.029	27	17.490	0.648	0.444	309.668
9	10	8	1.023	52	17.697	0.340	0.500	372.836
9	13	9	0.959	21	-24.160	-1.150	0.571	263.539
3	6	12	0.922	28	-59.406	-2.122	0.536	265.525
3	6	11	0.908	27	-70.792	-2.622	0.519	270.623
10	13	9	0.890	27	-75.869	-2.810	0.407	301.416

表 4-8 MACD 策略 2020 上证 50 参数值结果 top10

Short	Long	Mid	PF	#T	NP	T_bar	PP	D_max
10	22	12	6.038	17	466.638	27.449	0.647	41.075
10	22	10	5.699	19	463.114	24.374	0.579	43.289
3	22	9	5.295	17	580.642	34.155	0.412	95.374
10	16	12	5.170	17	417.903	24.583	0.529	46.283
10	23	11	4.608	13	538.909	41.455	0.538	98.923
10	23	12	4.439	13	507.046	39.004	0.538	119.648
3	22	10	4.242	21	546.504	26.024	0.429	76.592
10	20	12	3.928	16	397.636	24.852	0.563	48.347
3	15	10	3.892	20	694.944	34.747	0.600	124.517
10	22	8	3.750	20	391.474	19.574	0.450	95.576

根据上述结果，对于两个策略回测期，最终选择最优参数如表 4-9 所示：

表 4-9 上证 50 疫情前后回测期对应 MACD 交易策略参数

回测期	最优参数
2019	[3,6,10]
2021	[10,22,12]

4.4 回溯测试交易策略

利用 4.2 求出的 MACD 最优参数组合，分别对 2019 年和 2021 年的数据进行了回测。根据 4.1 节的结果，对于疫情前后两个阶段，随机森林都是最好的机器学习预测方法，因此选择随机森林算法与 MACD 策略结合。根据不同历史窗口长度所对应的误差，选择达到最小误差的 w 。对于疫情前的回测，将上证 50 指数的 w 设置为 6，将 h 设置为 10；对于疫情后的回测，将上证 50 指数的 w 设置为 6，将 h 设置为 10。普通 MACD 策略与混合 MACD 策略的回测结果如下图所示。对于每个策略，给出了如下评价指标：盈亏比 PF,交易的总数#T,净利润 NP,每笔交易平均利润 $\bar{T}$ ，利润百分比 PP 和最大回撤 D_{max} 。所提出的混合交易策略被表示为 hMACD 策略。

表 4-10 上证 50MACD 与 hMACD 策略结果对比

回测期	策略	PF	#T	NP	T_bar	PP	D_max
2019	MACD	2.10	27	42.56	15.76	0.52	175.90
	hMACD	3.74	4	57.80	14.45	0.75	21.08
2021	MACD	0.52	19	-435.52	-22.92	0.37	633.43
	hMACD	0.42	3	-107.41	-35.80	0.67	185.33




图 4-1 2019 上证 50 指数 MACD 策略交易信号图




图 4-2 2019 上证 50 指数 hMACD 策略交易信号图




图 4-3 2021 上证 50 指数 MACD 策略交易信号图




图 4-4 2021 上证 50 指数 hMACD 策略交易信号图

图 4-1 至图 4-4, 为 2019 及 2021 年 MACD 策略和 hMACD 策略产生的交易信号图。由上图可以看出, hMACD 策略有效减少了交易信号。对表 4-10 输出结果进行分析: 2019 年, 盈亏比 PF 、净利润 NP 和利润百分比 PP 均有所提高, 同时也都减少了交易的总数 $\#T$ 和最大浮动亏损 D_{max} 。尽管在 MACD 策略下, 上证 50 可以盈利, 但是改进后的混合策略一定程度上提高了盈利能力。2021 年, hMACD 策略盈亏比 PF 有所下降, 但是也减少了交易总数 $\#T$ 、净亏损 NP 、最大回撤 D_{max} , 增大了利润百分比 PP , 因为 2021 疫情形势仍反复波动, 由 2020 年数据回测出的最优 MACD 参数在 2021 年的策略中表现弱于 2018 年回测的最优参数在 2019 年策略中的应用。

为了进一步研究 hMACD 策略的适用性, 我们将 MACD 策略及 hMACD 策略与上证 50ETF 基金数据进行比较, 和大盘比较看是否能跑赢大盘、带给我们更多收益。因为上证 50 指数与上证 50ETF 指数走势基本相同, 所以可以直接用我们上述研究的得到的各项最优参数进行回测。图 4-5 至图 4-8 为回测结果。




图 4-5 2019MACD 策略上证 50ETF 回测图



图 4-6 2019hMACD 策略上证 50ETF 回测图



图 4-7 2021MACD 策略上证 50ETF 回测图




图 4-8 2021hMACD 策略上证 50ETF 回测图

从上述结果中可以发现：2019 年，与 MACD 策略相比，hMACD 策略各项指标都有了很大改善，hMACD 策略年化收益率达到了 43.4%，远远超过了 MACD 策略的 11.2%，与 MACD 策略相比，hMACD 策略各项指标都有了改善。最大回撤率 3.8%。从整体趋势上来看，后半段累计收益率稳定超过基准累计收益率，持续增大收益。2021 年，大盘累计收益率总体趋势持续下降，呈波动趋势，这也对应了 2021 年反复严重的疫情，MACD 策略的年化收益率基本与大盘指数持平，而 hMACD 策略虽然在前半年表现不佳，但后半年在大盘指数波动的冲击下，止住了颓势，到 21 年底累计收益率逐渐增加。对比 hMACD 策略在 19 年和 21 年的表现可以发现，当大盘行情向好时，hMACD 策略可以抓住时机，大大提高收益，而当行情波动时，hMACD 策略也可以有效避开价格震荡区域，减少、避免下跌风险。

4.5 沪深 300 和中证 500 实证分析

为了进一步研究本文提出的 hMACD 策略的适用性，分别对沪深 300 和中证 500 进行实证分析。上证 50、沪深 300 和中证 500 作为国内的三大指数，具有其相似性，问题规模是相近的，比如在遇到股灾、疫情、国家市场的经济政策颁布修改时，它们受到的冲击和影响基本是一样的。另一方面，一定情况下，历史窗口长度增长有正面效果，到达一定范围后，会增加训练时间，影响预测效率。因此我们结合前文的计算方法和结果，对沪深 300 和中证 500 进行预测时，将历史窗口长度 w 设置为 6 个交易日，将预测期 h 设为 10。

分别利用 2018 年和 2020 年沪深 300 和中证 500 的交易日数据回测最优 MACD 参数，计算结果如表 4-11 至表 4-14。

表 4-11 MACD 策略 2018 沪深 300 参数值结果 top10

Short	Long	Mid	PF	#T	NP	T_bar	PP	D_max
3	7	9	1.889	20	382.459	19.123	0.550	145.397
3	8	9	1.706	20	282.998	14.150	0.550	222.977
3	7	11	1.521	21	221.717	10.558	0.619	185.778
3	7	10	1.505	22	275.063	12.503	0.545	244.870
3	8	8	1.336	22	175.316	7.969	0.500	167.948
3	7	8	1.244	24	137.413	5.726	0.417	172.920
3	6	9	1.158	29	131.141	4.522	0.483	363.359
3	7	12	1.140	23	79.871	3.473	0.478	243.635
3	8	10	1.067	21	42.134	2.006	0.571	182.682
3	6	8	1.059	27	49.153	1.820	0.481	312.162

表 4-12 MACD 策略 2018 中证 500 参数值结果 top10

Short	Long	Mid	PF	#T	NP	T_bar	PP	D_max
3	23	12	1.302	18	246.906	13.717	0.389	350.762
3	7	8	1.197	25	171.424	6.857	0.480	601.199
7	21	10	1.088	14	67.221	4.801	0.429	667.397
4	20	8	1.077	18	71.117	3.951	0.333	559.409
4	25	12	1.069	14	49.560	3.540	0.500	443.059
5	19	11	1.059	15	40.572	2.705	0.533	426.398
6	24	10	1.058	15	43.184	2.879	0.400	671.570
5	21	12	1.056	12	40.486	3.374	0.333	461.666
3	8	8	1.056	25	59.130	2.365	0.480	702.312
3	25	12	1.049	21	51.709	2.462	0.476	474.663

表 4-13 MACD 策略 2020 沪深 300 参数值结果 top10

Short	Long	Mid	PF	#T	NP	T_bar	PP	D_max
10	24	8	5.230	17	1013.288	59.605	0.706	136.072
9	26	12	4.712	12	1026.851	85.571	0.667	137.923
3	11	9	4.621	20	1412.325	70.616	0.650	288.976
10	24	11	4.584	13	903.320	69.486	0.769	100.851
10	24	10	4.562	13	897.731	69.056	0.769	100.851
3	27	9	4.290	16	863.748	53.984	0.625	175.546
3	11	8	4.247	21	1289.305	61.395	0.667	295.932
9	22	12	4.049	15	950.921	63.395	0.733	160.788
3	8	12	3.995	23	1118.568	48.633	0.652	206.671
5	8	8	3.941	23	1497.943	65.128	0.652	230.734

表 4-14 MACD 策略 2020 中证 500 参数值结果 top10

Short	Long	Mid	PF	#T	NP	T_bar	PP	D_max
10	26	12	7.452	11	1398.509	127.137	0.818	150.595
10	27	8	5.862	16	1272.760	79.548	0.750	152.498
10	26	11	5.194	12	1281.337	106.778	0.750	150.595
10	26	9	4.710	13	1197.337	92.103	0.692	150.595
10	27	12	4.639	8	931.610	116.451	0.500	242.271
10	26	10	4.635	12	1151.873	95.989	0.667	150.595
10	26	8	4.449	14	1137.119	81.223	0.571	150.595
10	27	9	3.772	13	1131.484	87.037	0.615	292.262
9	27	10	3.752	11	874.007	79.455	0.455	117.525
9	27	9	3.482	14	955.985	68.285	0.571	196.785

将各参数汇总如下，见表 4-15。

表 4-15 回测参数表				
指数	回测期	w	h	MACD 参数
沪深 300	2019	6	10	[3,7,9]
	2021	6	10	[10,24,8]
中证 500	2019	6	10	[3,23,12]
	2021	6	10	[10,26,12]

分别将 MACD 策略及 hMACD 策略与沪深 300ETF 和中证 500ETF 基金数据进行比较。



图 4-9 2019MACD 策略沪深 300ETF 回测图




图 4-10 2019hMACD 策略沪深 300ETF 回测图

由图 4-9、图 4-10 可以看出 hMACD 策略将年化收益率由 MACD 策略的 16.9% 提高到 33.6%，夏普比率由 0.88 变为 2.35，虽然 hMACD 策略没有全面跑赢大盘，只在年初时表现较好，但是在年底时累计收益率逐渐追平基准累计收益率。



图 4-11 2021MACD 策略沪深 300ETF 回测图



图 4-12 2021hMACD 策略沪深 300ETF 回测图

由图 4-11、图 4-12 可以看出 hMACD 策略将年化收益率转负为正，在大盘累计收益率波动下降时减少了风险，控制买入和卖出，在行情渐好时及时抓住时机。年化收益率由 MACD 策略的-8.1%提高到 3.9%，夏普比率由-0.88 变为 0.03。




图 4-13 2019MACD 策略中证 500ETF 回测图




图 4-14 2019hMACD 策略中证 500ETF 回测图

由图 4-13、图 4-14 可以看出，2019 年，回测 MACD 策略和 hMACD 策略都可以在大部分时间内跑赢大盘，获得较高收益。hMACD 策略也在 MACD 策略的基础上进一步优化了买入卖出信号，将年化收益率由 MACD 策略的 30.7%提高到 43.1%，夏普比率由 1.54 变为 2.33。



图 4-15 2021MACD 策略中证 500ETF 回测图



图 4-16 2021hMACD 策略中证 500ETF 回测图

由图 4-15、图 4-16 可以看出，2021 年，回测 MACD 策略和 hMACD 策略累计收益率基本都低于基准累计收益率，但 hMACD 策略仍在盈利，虽然上半年累计收益率较低，但是下半年抓住了行情上涨时机，增加了一定收益。

综合上证 50ETF、沪深 300ETF 和中证 500ETF 两个阶段的回测结果来看：在疫情前阶段，hMACD 可以很好地提高 MACD 策略的盈利，在行情向好时抓住时机，大幅提高利润，但当本身大盘行情就很好时，也很难使用 hMACD 策略超过基准累计收益率，获得更高的利润。在疫情后阶段，因为疫情影响，股市波动较多且大多呈颓势，hMACD 策略也可以有效避开价格震荡区域，减少、避免下跌风险。

结 论

本文提出了一种新的混合技术分析策略流程来优化产生的买入或卖出信号。在本文中,该交易策略是基于混合技术分析规则与机器学习模型的预测能力提出的。在本文的研究中,使用国内三大指数:上证 50、沪深 300 和中证 500,2012-2021 十年间的每日交易数据。为了客观对比分析该优化策略的盈利效果,本文将数据划分为新冠疫情前阶段和新冠疫情爆发后阶段,即 2012 年-2019 年和 2020 年-2021 年。

本文首先使用上证 50 指数 2012-2021 年的每个交易日数据,分别测试支持向量回归、随机森林和人工神经网络三种方法对股票市场价格的预测效果。在所有被测试的机器学习技术中,随机森林算法表现最好,支持向量回归算法次之,人工神经网络算法在预测中的表现很不理想,我们在进一步的预测中也再次证明了这一点。随机森林算法的良好预测效果表明,随机森林模型适用于股票市场价值短期预测。

在选择出最优机器学习技术后,本文在 MACD 策略的基础上,使用机器学习方法预测出的股票价格与当前股票价格,增加了一个判断买卖信号的趋势判断指标,以此来优化经典的 MACD 择时策略。本文还优化了 MACD 的参数设置,对于 2018 年和 2020 年三大指数的数据,使用网格搜索,分别回测出当年的最优 MACD 参数,将其用于 2019 和 2021 年的策略回测中。

我们使用三大指数 2019 年和 2021 年的数据对优化的混合技术分析策略进行回测,证明了该策略一定程度上可以帮助投资者在股票市场获得更高且更稳定的收益。该混合策略不仅提高了利润,还减少了交易次数和亏损风险。在此基础上,本文还进一步以上证 50ETF、沪深 300ETF 和中证 500ETF 基金指数为基准,测试优化策略效果。研究发现,在疫情前阶段,该优化策略可以很好地提高盈利,在行情向好时抓住时机,大幅提高利润。在疫情后阶段,因为疫情影响,股市波动较多且大多呈颓势,该策略也可以有效避开价格震荡区域,减少下跌风险。

本文学习与研究了国内外关于结合技术分析策略与机器学习方法的混合模型及研究成果,并将其应用于国内股票市场,通过疫情前后的回测结果发现本文提出的混合模型可以一定程度上提高投资者收益。但在研究过程中仍存在一些问题和可以改进的地方:

(1) 进一步细化趋势判断指标,将预测期内的趋势变化也考虑进来,预测期内的趋势变化有时也可以揭示股市的变动趋势,将其综合进来,可以优化产生的交易信号。

(2) 预测期长度可以优化。在本文的研究过程中发现，设定过长的预测期效果极不理想，误差很大，因此，在未来的工作中，可以对股票市场价值的预测模型进行进一步的优化，提高预测期长度，以便优化对更长期的股票市场价值的判断，并使用其他股票市场指数的最新数据以及外汇市场数据进行验证。

(3) 机器学习方法的参数可以优化。由于硬件限制，本文训练且设置的参数仍存在一些问题，比如增大历史窗口并不能有效提高预测精度，因此未来可以对预测模型进行进一步的优化。

参考文献

- [1] Aguirre, A. A. A., Medina, R. A. R., & Méndez, N. D. D. (2020). Machine learning applied in the stock market through the Moving Average Convergence Divergence (MACD) indicator. *Investment Management and Financial Innovations*, 17(4), 44-60.
- [2] ANDREW, W. L. (2004). The Adaptive Markets Hypothesis. *Journal of Portfolio Management*, 30(5), 15-29.
- [3] Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383-417.
- [4] Gencay, R. (1996). Non-linear Prediction of Security Returns with Moving Average Rules. *Journal of Forecasting*, 15(3), 165-174.
- [5] Hong, H., Jeremy, C., & Stein, A. (1999). Unified Theory of Underreaction, Momentum Trading, and Overreaction in Asset Markets. *The Journal of Finance*, 54(6), 2143-2184.
- [6] Jegadeesh, N. (1990). Evidence of Predictable Behavior of Security Returns. *Journal of Finance*, 45(3), 881-898.
- [7] Pesaran, H., & Timmermann, A. (1999). Model Instability and Choice of Observation Window. *University of California at San Diego, Economics Working Paper Series*, 73(2), 1-16.
- [8] Pring, M. J. (1961). *Technical analysis explained: the successful investor's guide to spotting investment trends and turning points*. McGraw-Hill.
- [9] Rajashree, D., & Pradipta, K. D. (2016). A hybrid stock trading framework integrating technical analysis with machine learning techniques. *The Journal of Finance and Data Science*, 2(1), 42-57.
- [10] Sang, C., & Pierro, M. D. (2019). Improving trading technical analysis with TensorFlow Long Short-Term Memory (LSTM) Neural Network - ScienceDirect. *The Journal of Finance and Data Science*, 5(1), 1-11.
- [11] Teixeira, L. A., & De Oliveira, A. L. I. (2010). A method for automatic stock trading combining technical analysis and nearest neighbor classification. *Expert Systems with Applications*, 37(10), 6885-6890.
- [12] Vapnik, V. N. (1995). *The Nature of Statistical Learning Theory*. Springer.
- [13] Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159-175.

- [14]陈标金,&王锋.(2019). 宏观经济指标、技术指标与国债期货价格预测——基于随机森林机器学习的实证检验. *统计与信息论坛*,34(06),29-35.
- [15]陈允平, 王旭蕊, &韩宝亮.(2002). *人工神经网络原理及其应用*. 中国电力出版社.
- [16]方匡南, 吴见彬, 朱建平, &谢邦昌.(2011). 随机森林方法研究综述. *统计与信息论坛*, 26(3),32-37.
- [17]方匡南, 朱建平, &谢邦昌.(2010). 基于随机森林方法的基金收益率方向预测与交易策略研究. *经济经纬*,2,61-65.
- [18]韩力群.(2002). *人工神经网络理论、设计及应用*. 化学工业出版社.
- [19]韩豫峰, 汪雄剑, 周国富, &邹恒甫.(2014). 中国股票市场是否存在趋势?. *金融研究*, 3,152-163.
- [20]姜富伟, 涂俊, Rapach, D. E., Strauss, J. K., &周国富.(2011). 中国股票市场可预测性的实证研究. *金融研究*,9,107-121.
- [21]李航.(2012). *统计学习方法*. 清华大学出版社.
- [22]李云红.(2015). *中国股票市场的适应性市场假说特征及相关应用研究*(博士学位论文, 西南交通大学).
- [23]孙德山.(2004). *支持向量机分类与回归方法研究*(博士学位论文,中南大学).
- [24]孙亮, &黄倩.(2017). *实用机器学习*.人民邮电出版社.
- [25]王上飞, 周佩玲, 吴耿峰, 付忠谦, 储阅春, &沈谦.(1998). 径向基神经网络在股市预测中的应用. *预测*,17(6),44-46.
- [26]王燕.(2005). *应用时间序列分析*. 中国人民大学出版社.
- [27]王永宏, &赵学军.(2001). 中国股市“惯性策略”和“反转策略”的实证分析. *经济研究*,6(3),56-61.
- [28]辛治运, &顾明. (2008).基于最小二乘支持向量机的复杂金融时间序列预测. *清华大学学报: 自然科学版*,48(7),1147-1149.
- [29]杨永洁.(2017). 基于优化 MACD 模型的股票价格变化趋势预测方法. *广西科学院学报*, 33(1),65-70.
- [30]余乐安, &汪寿阳.(2009)基于核主元聚类的股票分类. *系统工程理论与实践*,29(12),1-8.
- [31]周志华.(2016). *机器学习*. 清华大学出版社.

致 谢

研究生的最后一年，好像乘坐了一辆超速列车，恍然就来到五月，提笔写到这里已近毕业，但总觉得第一次来到这里还是昨天。虽然入学的第一年就遇到了新冠疫情，在学校的时间很少，但在同学和老师们的陪伴下也度过了非常充实的三年。

首先要感谢我的导师贾广岩教授，从论文的初次选题到后面遇到问题时提供新的论文思路方向，以及实证部分的内容补充方面都给予我很多帮助与建议。还要感谢三年来我的专业课老师们，感谢你们的教育与帮助，向老师们致以敬意和由衷的感谢。

其次要感谢我的朋友们。读研三年期间，有两年多都处于疫情中，生活中也碰到了很多烦恼与挫折，是你们在我遇到困难时给予我继续前进的勇气，在失落时成为指引我前进的路标。感谢我的好朋友天爱对我的帮助与鼓励，遇到问题时帮助我一起分析改进。虽然我们不在同一个地方，但是也都马上要迈入人生的新阶段，希望朋友们都能找到自己喜欢的方向追求梦想。

最后要感谢我的父母，无论何时都支持我的想法和选择，是我最温暖最坚实的避风港，总是无微不至的包容我关心我，让我可以自由勇敢地选择未来的人生。

学位论文评阅及答辩情况表

论文评阅人	姓 名		专业技术 职 务	是否博导 (硕导)	所 在 单 位		总体评价
	匿名评阅						良好
	匿名评阅						良好
	匿名评阅						良好
答辩委员会成员	姓 名		专业技术 职 务	是否博导 (硕导)	所 在 单 位		
	主席	张奇	教授	博导	复旦大学数学院		
	委 员	何勇	研究员	硕导	山东大学金融研究院		
		杨淑振	副教授	硕导	山东大学金融研究院		
答辩委员会对论文的 总体评价			良好	答辩秘书	李蔚郁	答辩日期	2022.05.20
备注							